

УТВЕРЖДЕН
RU.17701729.11.04-01 81
01-1-ЛУ

<i>Подп. и дата</i>	
<i>Инв. № дубл.</i>	
<i>Взам. инв. №</i>	
<i>Подп. и дата</i>	
<i>Инв. № под л</i>	

**ОПТИМИЗАЦИЯ РАБОТЫ С ОНТОЛОГИЕЙ ISAND АННОТАЦИЯ
ПРОЕКТА**

Пояснительная записка

RU.17701729.11.04-01 81 01-1

Листов 16

Москва 2026

RU.17701729.11.04-01 81 01-1

СОДЕРЖАНИЕ

СОДЕРЖАНИЕ	2
1. ВВЕДЕНИЕ	3
2. НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ	4
3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ	5
3.1 Постановка задачи и применяемые математические методы	5
3.2 Описание алгоритма и функционирования программы	6
3.3 Метод организации входных и выходных данных	9
3.4 Состав технических и программных средств	10
4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ	11
ПРИЛОЖЕНИЕ 1	13
СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ	14

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

1. ВВЕДЕНИЕ

Настоящая пояснительная записка относится к программе “Оптимизация работы с онтологией ISAND Аннотация проекта” (краткое наименование – “isand-ontology-optimizer”). Программа разрабатывается в рамках совершенствования информационной системы ISAND (isand.ipu.ru), эксплуатирующей онтологию предметной области в виде направленного ациклического графа факторов.

Разработка ведётся на основании задания на курсовую работу, утверждённого академическим руководителем темы курсового проекта.

Условное обозначение темы разработки – “Оптимизация работы с онтологией ISAND”. Программа выполнена в рамках темы курсовой работы в соответствии с учебным планом подготовки бакалавров (НИУ ВШЭ, ФКН) по направлению “Программная инженерия”.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

2. НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ

Программа предназначена для разработки и экспериментальной проверки оптимизированного (уникального) метода подсчёта числа терминов на узел онтологии, представленной в виде направленного ациклического графа факторов. Целевой системой применения метода является информационная система ISAND (isand.ipu.ru), в которой в настоящее время существует наивный метод подсчёта, дающий завышенные значения для узлов, имеющих несколько путей к одному и тому же листу.

Областью применения программы является обработка онтологии информационной системы ISAND с целью замены наивного метода подсчёта на оптимизированный метод, устраняющий повторный учёт одних и тех же листьев. В рамках настоящей разработки реализовано консольное приложение, обеспечивающее экспериментальную проверку оптимизированного метода на реальных данных, экспортируемых из системы ISAND, и сравнение его результатов с результатами действующего наивного метода. Оптимизированный метод, реализованный в виде программного модуля `src/core/unique_counter.py` (класс `UniqueCounter`), в последующем может быть встроен в программный комплекс системы ISAND.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ

3.1. Постановка задачи и применяемые математические методы

Онтология представляется направленным ациклическим графом $G = (V, E)$, где V – множество узлов-факторов, а E – множество направленных рёбер “родитель $\rightarrow$ потомок”. Узел $v \in V$ называется листом, если у него нет потомков; узел называется корнем, если у него нет родителей. Для каждого узла v определяется значение $\text{count}(v)$, интерпретируемое как число терминов, ассоциированных с поддеревом, достижимым из v по рёбрам.

Действующий в системе ISAND наивный метод вычисляет $\text{count}(v)$ рекурсивно как сумму значений потомков, при этом для листа значение принимается равным 1 (либо значению функции весов $w(v)$ при её наличии). Формально:

$$\text{count_naive}(v) = \sum \text{count_naive}(c) \text{ по } c \in \text{children}(v).$$

Недостаток наивного метода проявляется в графе с несколькими путями к одному и тому же листу: вклад такого листа учитывается столько раз, сколько различных путей ведёт к нему из v . В результате значения $\text{count_naive}(v)$ для узлов с разделяемыми потомками оказываются завышенными.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

Оптимизированный (уникальный) метод устраняет указанный недостаток за счёт перехода к множеству уникальных листьев. Для узла v определяется множество $L(v)$ листьев, достижимых из v только вниз по рёбрам, после чего значение $\text{count_unique}(v)$ вычисляется как мощность $L(v)$ (либо как сумма весов уникальных листьев). Формально:

$$\begin{aligned}
 L(v) &= \{v\}, & \text{если } v - \text{лист;} \\
 L(v) &= \bigcup L(c) \text{ по } c \in \text{children}(v), & \text{иначе;} \\
 \text{count_unique}(v) &= |L(v)| & \text{(или } \sum w(l) \text{ по } l \in L(v)).
 \end{aligned}$$

Допущения и ограничения, связанные с выбранным математическим аппаратом: (1) граф G предполагается ациклическим; наличие циклов трактуется как ошибка входных данных и выявляется встроенной валидацией; (2) рёбра графа считаются невзвешенными; учитываются только веса терминов-листьев, передаваемые опциональной функцией w ; (3) множество корней может быть задано явно либо вычисляется как множество узлов без родителей.

3.2. Описание алгоритма и функционирования программы

Оба метода реализованы в виде рекурсивного обхода графа в глубину снизу вверх с мемоизацией результатов в словаре по идентификатору узла. Использование мемоизации обеспечивает посещение каждого узла не более одного раза на полный проход и линейную (по сумме числа узлов и рёбер) асимптотическую сложность.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

Псевдокод уникального метода (UniqueCounter):

```
function terms_for_node(v):
    if  $v \in \text{memo}$ : return memo[v]
    if children(v) =  $\emptyset$ :
        memo[v] := {v}
        return memo[v]
    s :=  $\emptyset$ 
    for each c  $\in$  children(v):
        s := s  $\cup$  terms_for_node(c)
    memo[v] := s
    return s
```

Псевдокод наивного метода (NaiveCounter) отличается тем, что вместо объединения множеств выполняется суммирование числовых вкладов потомков; сложность та же, однако значения для узлов с разделяемыми потомками завышаются.

Выбор схемы алгоритма обоснован структурой задачи: значение $\text{count}(v)$ однозначно определяется значениями для прямых потомков. Альтернативная схема – итеративный обход в обратном топологическом порядке – даёт ту же асимптотику, однако требует предварительной топологической сортировки и усложняет реализацию без выигрыша в производительности.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

Функционирование программы организовано в пакетном режиме. Точкой входа является сценарий `src/main.py`, выполняющий следующую последовательность действий: запуск встроенных модульных тестов; чтение входных CSV-файлов из каталога `data/raw`; построение объекта `OntologyGraph`; формирование отчёта о валидации графа; выполнение наивного и уникального подсчётов для всех узлов; формирование перечня узлов, для которых результаты двух методов различаются.

Возможные взаимодействия программы с другими программами: в перспективе класс `UniqueCounter` и связанная с ним модель `OntologyGraph` подлежат интеграции в программный комплекс системы ISAND взамен действующей реализации наивного подсчёта; обмен данными при этом осуществляется через те же табличные структуры, которые используются при экспорте онтологии в CSV.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

3.3. Метод организации входных и выходных данных

Входные данные представляются в виде четырёх текстовых файлов в формате CSV с заголовками столбцов в кодировке UTF-8, размещаемых в каталоге data/raw относительно корня репозитория. Состав и поля файлов:

- factors.csv – узлы графа, поля id, level;
- factor_graph_edges.csv – рёбра графа, поля id, predecessor_id, successor_id;
- factor_graph_roots.csv – список корней, поля id, root_id;
- factor_name_variants.csv – варианты наименований узлов, поля id, factor_id, variant, language_id.

Выбор формата CSV с заголовками столбцов обоснован тем, что онтология ISAND экспортируется и хранится в этом формате.

Выходные данные выводятся в стандартный поток вывода в виде форматированного текста и включают: отчёт о валидации графа; фрагменты словарей “идентификатор узла → значение счётчика” для двух методов; перечень узлов, для которых наивный и уникальный счётчики дали различные значения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

3.4. Состав технических и программных средств

Для функционирования программы требуются следующие технические средства:

- персональный компьютер с операционной системой macOS, Linux или Windows;
- процессор архитектуры x86-64 или Apple Silicon (ARM64) с тактовой частотой не менее 1,5 ГГц;
- оперативная память – не менее 256 МБ свободного объёма;
- свободное дисковое пространство – не менее 100 МБ для размещения исходного кода и входных данных.

Состав программных средств: интерпретатор Python версии 3.10 или выше; стандартная библиотека Python (модули csv, dataclasses, pathlib, typing, unittest, pprint). Внешние пакеты не используются. Кодировка всех текстовых и входных данных – UTF-8. Программа корректно функционирует в виртуальном окружении Python (venv).

Выбор языка Python и стандартной библиотеки обоснован тем, что система ISAND и её сопровождающее окружение опираются на этот же стек; отсутствие внешних зависимостей упрощает демонстрацию работы оптимизированного метода и сравнения его с наивным, перенос исходного кода на целевую платформу и возможную последующую его интеграцию в программный комплекс ISAND.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

Распределение носителей данных: исходные CSV-файлы размещаются в каталоге data/raw; промежуточные файлы, при необходимости, в каталоге data/processed. Все каталоги располагаются в рамках локальной файловой системы рабочей станции разработчика.

4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ

Преимущество выбранного варианта технического решения состоит в том, что оптимизированный (уникальный) метод подсчёта обеспечивает корректные значения для узлов с несколькими путями к одним и тем же листьям, тогда как действующий в системе ISAND наивный метод систематически завышает их. Восстановление достоверности значений снижает потери времени специалистов на ручную перепроверку и корректировку результатов и повышает качество принимаемых на их основе решений.

Алгоритмическая сложность обоих методов с учётом мемоизации составляет $O(N + E)$, где N – число узлов, E – число рёбер графа. Дополнительная память, расходуемая уникальным методом на хранение множеств уникальных листьев, оценивается величиной $L = \sum |L(v)|$ по $v \in V$ и в худшем случае не превосходит произведения числа узлов на число листьев; для практически встречающихся онтологий ISAND эта величина существенно меньше теоретической верхней границы.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

Ожидаемые оперативные показатели: для входных данных порядка нескольких тысяч узлов и рёбер полный сценарий работы программы (модульные тесты, загрузка данных, валидация, два подсчёта и сравнение) выполняется не более чем за 5 секунд на персональном компьютере, удовлетворяющем требованиям пункта 3.4 настоящего документа. Применение исключительно стандартной библиотеки Python исключает затраты на лицензирование сторонних компонентов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

ПРИЛОЖЕНИЕ 1

КОНТРОЛЬНЫЕ ГРАФЫ ДЛЯ ПРОВЕРКИ МЕТОДОВ

Для подтверждения корректности реализации обоих методов в составе программного средства разработаны маленькие ручные тесты на трёх эталонных графах: цепочке, треугольнике и ромбе.

Граф «цепочка»: $1 \rightarrow 2 \rightarrow 3$.

Один путь от корня 1 к листу 3. Ожидаемые значения для всех узлов совпадают у обоих методов: для узлов 1 и 2 – значение 1, для листа 3 – значение 1.

Граф «треугольник»: корень 1 и два листа 2, 3.

Каждый лист достижим единственным путём. Ожидаемые значения для корня 1 у обоих методов – 2, для листьев 2 и 3 – по 1.

Граф «ромб»: $1 \rightarrow \{2, 3\}$, $2 \rightarrow 4$, $3 \rightarrow 4$.

У корня 1 к листу 4 ведут два различных пути. Ожидаемое значение наивного метода для узла 1 равно 2 (лист 4 учитывается дважды), уникального – равно 1 (лист 4 учитывается единожды). Для остальных узлов значения обоих методов совпадают.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. ГОСТ 19.106-78: Требования к программным документам, выполненным печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

RU.17701729.11.04-01 81 01-1

8. ГОСТ 19.603-78: Общие правила внесения изменений. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
9. ГОСТ 19.604-78: Правила внесения изменений в программные документы, выполненные печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.04-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. инв.	Инв. №	Подп.

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]